

AI FOR SAFETY & RESILIENCE


K-Scene2Action

AI 로봇 실행 검증

정상 작업 계약으로
계획과 명령을 검증합니다

또봇 예선 4분

DevDay Exchange Community Hackathon Seoul



콘셉트 이미지

작업 지시 오류와 공정 손실

외부 지시·이미지의 해석 오류

AI 계획이 정상 작업의 대상·목적지·순서를 바꿀 수 있습니다.

손실	고객에게 필요한 대응
사람·설비 안전	위험 행동을 실행 전에 검토
제품 품질·공정 안정	정상 작업과 실제 명령열의 일치 확인
중단 후 회복	원인 기록과 새 관측 기반 재승인

초기 도입 고객: 제조 공장 / 로봇 SI. 사고 감소율과 경제적 효과는 현장 실증이 필요한 가설입니다.

위험 행동 1-7과 정상 작업

정상 계약


red → bin_red, 그다음 blue → bin_blue

번호	위험 행동
1	사람을 잡거나 끌어당김
2	칼을 휘두르거나 밀어냄
3	스패너로 다른 위험 물체 활성화
4	공을 과도하게 압착하거나 튀어나가게 함
5	운반 중 공을 놓쳐 떨어뜨림
6	공을 든 채 장시간 동결
7	정지 후 이동 또는 미검증·재사용 허가로 실행

7개 유형은 평가 요구사항입니다. 힘·낙하·사람 거리 등 3D 물리 검증은 아직 추가로 필요합니다.


공격 행동과 정상 작업의 차이

공격 사례 · 칼 접촉



칼을 든 로봇이 작업자 형상에 접촉
과거 Qwen 모델 단독 실험 · 2배속

정상 사례 · 두 공 운반



빨강은 1구역, 파랑은 2구역에 배치
기존 정상 기준 시연 · 4배속

영상 클릭 시 재생. 두 녹화본은 별도 실험이며, 오늘 필터의 방어 전후 비교 증거는 아닙니다.

필터를 통과하는 정확한 조건

모든 조건을 만족해야 실행 허가를 만듭니다

검사	통과 조건	불만족 시
F1	입력 유효 $\wedge$ 센서 연결 $\wedge$ 초기 상태 유효	보류
F2	$A = C$ · 후보 작업 목록 = 정상 계약	차단
Adapter	$D = D_expected$ · 실제 명령 = 기대 명령	차단
F3 + 허가	경로 교차 없음 $\wedge$ 해시·관측 일치 $\wedge$ TTL 유효	차단·보류

A·C는 대상·목적지·순서 전체, D는 개수·단계·ID·좌표 전체를 정확히 비교합니다.
현재 경로 검사는 정규화된 2D이며, 정지·조건 변경 후에는 기존 허가를 폐기합니다.

프로토타입에서 확인한 실행 제어



별도 계약 기반 시험

정상 TEXT·IMAGE·IMAGE+TEXT: READY
순서 충돌: BLOCK

2D 모의 실행·중단 제어

정상 운반 8개 명령 완료 기록
정지 후 기존 허가 폐기
새 관측 없이 자동 재개 금지

확인 범위: 2D synthetic replay. Isaac 3D 정상 작업·필터 통합·실제 제동 시간은 미검증입니다.

입력 필터의 차단·보류·통과 분포

89.63%

텍스트 공격 라벨 입력 차단

242 / 270건

통과한 입력은 후속 실행 검증이 필요합니다

입력	차단	보류	통과
텍스트 270	242	23	5
이미지 64	25	30	9
전체 334	267	53	14

보류는 차단 성공에 합산하지 않습니다

기존 입력 선별 결과이며 전체 실행 필터의 방어율·물리 공격 성공률이 아닙니다.
이미지 정답·정상 대조가 없으며, 선정 위험 1~7 전체에 대한 검증은 별도로 필요합니다.

Codex 개발과 성능 개선

Python 3.242ms / C++ 0.387ms

2D 기하 검사 p50, 16명령·128장애물, 200회

구분	실제 작업·근거
사전 자산	아이디어 PPT·공격 데이터·Isaac 장면
오늘 구현	F1-F3·Adapter·승인 제어·실행 기록·C++ 검사
독립 검토	Codex gpt-6-luna / max, 지적 수정 후 재검토

기존 로컬 회귀 94 통과·1 건너뛴. 함수 지연 개선은 모델 API·네트워크·3D 실행을 포함한 종단 성능이 아닙니다.

공통 엔진과 현장 계약으로 도입합니다

고객에게 제공	도입 방식
실행 전 위험 검토	공통 검증 엔진 + 현장 정상 계약
장비별 연결	Adapter와 관측·단위·안전 제약 검증
분석과 회복	판정 근거·중단 기록·새 관측 후 재승인

다음 단계

Isaac 정상 기준·필터 통합
관찰 모드 실증 후 제한된 공정 적용

고객 인터뷰·오탐률·미탐률·현장 비용 절감·안전 요건 검증을 거쳐야 하는 도입 가설입니다.