


AI FOR SAFETY & RESILIENCE

K-Scene2Action

AI 로봇 실행 검증

정상 작업 계약으로
계획과 명령을 검증합니다

또봇 결선 10분
DevDay Exchange Community Hackathon Seoul



콘셉트 이미지

로봇 공장의 위험과 손실

사람과 설비

사람 접촉과 위험 도구 사용은 안전 문제로 이어집니다

품질과 생산

압착·낙하·정지 실패는 작업 손실과 중단을 만듭니다

운영과 회복

중단 원인을 남기고, 새로운 관측으로 재검증합니다

대상 공정과 손실 규모는 고객 인터뷰·현장 데이터로 추가 확인할 계획입니다.

위험 행동 1-7과 정상 작업

정상 계약


red → bin_red, 그다음 blue → bin_blue

번호	위험 행동
1	사람을 잡거나 끌어당김
2	칼을 휘두르거나 밀어냄
3	스패너로 다른 위험 물체 활성화
4	공을 과도하게 압착하거나 튀어나가게 함
5	운반 중 공을 놓쳐 떨어뜨림
6	공을 든 채 장시간 동결
7	정지 후 이동 또는 미검증·재사용 허가로 실행

7개 유형은 평가 요구사항입니다. 힘·낙하·사람 거리 등 3D 물리 검증은 아직 추가로 필요합니다.


공격 행동과 정상 작업의 차이

공격 사례 · 칼 접촉



칼을 든 로봇이 작업자 형상에 접촉
과거 Qwen 모델 단독 실험 · 2배속

정상 사례 · 두 공 운반



빨강은 1구역, 파랑은 2구역에 배치
기존 정상 기준 시연 · 4배속

영상 클릭 시 재생. 두 녹화본은 별도 실험이며, 오늘 필터의 방어 전후 비교 증거는 아닙니다.

필터를 통과하는 정확한 조건

모든 조건을 만족해야 실행 허가를 만듭니다

검사	통과 조건	불만족 시
F1	입력 유효 $\wedge$ 센서 연결 $\wedge$ 초기 상태 유효	보류
F2	$A = C$ · 후보 작업 목록 = 정상 계약	차단
Adapter	$D = D_expected$ · 실제 명령 = 기대 명령	차단
F3 + 허가	경로 교차 없음 $\wedge$ 해시·관측 일치 $\wedge$ TTL 유효	차단·보류

A·C는 대상·목적지·순서 전체, D는 개수·단계·ID·좌표 전체를 정확히 비교합니다.
현재 경로 검사는 정규화된 2D이며, 정지·조건 변경 후에는 기존 허가를 폐기합니다.

F1: 입력과 관측의 유효 조건

$$F1 = \text{ModeOK} \wedge \text{SensorOnline} \wedge \neg \text{Busy} \wedge \neg \text{Fault} \\ \wedge (\text{held} = \text{None}) \wedge (\text{관측 나이} \leq 1\text{초})$$

조건	구체 기준
ModeOK	IMAGE: 사용자 텍스트 없음 TEXT·IMAGE_TEXT: 비어 있지 않은 텍스트
상태	센서 연결, 실행·fault 없음, 들고 있는 물체 없음
실패 처리	스키마 오류는 요청 거부, 상태 불일치는 HOLD

관측 나이 = 현재 시각 - observed_at. 모든 조건을 동시에 만족해야 후속 검사를 진행합니다.
현재는 합성 2D 상태를 재관측하며 실제 센서 프레임·Codex AI 런타임 통합은 미완료입니다.

F2·Adapter: 정확한 목록 일치

F2 통과 $\Leftrightarrow A = C$ / Adapter 통과 $\Leftrightarrow D = D_expected$

기호·조건	정확히 비교하는 내용
$A = C$	후보 A와 서버 계약 C의 작업 개수·대상·목적지·순서
$D = D_expected$	명령 개수·단계·대상 ID·목적지 ID·좌표
정상 작업 예시	[(red, bin_red), (blue, bin_blue)] 각 작업 4단계, 총 8개 명령
차단 조건	작업 1개 또는 명령 1개라도 불일치하면 BLOCK

$D_expected$ 는 서버 계약과 관측에서 독립적으로 계산합니다.

현재는 정확한 목록 비교이며, 의미 유사도 점수나 위험 점수 임계값을 사용하지 않습니다.

F3: 선분 교차와 허가 유효 조건

경로 통과 $\Leftrightarrow$ 모든 이동 선분 $L_i \cap$ 확대 장애물 $B_j^+ = \emptyset$

$$B^+ = [x_{\min}-r, x_{\max}+r] \times [y_{\min}-r, y_{\max}+r], r = 0.045$$

검사	통과 기준
작업 경계	이동점 $\in [r, 1-r]^2$, 장애물 접촉·교차는 BLOCK
실행 허가	$H(C) = \text{승인 계약 해시} \wedge H(D) = \text{승인 명령 해시}$
관측·시간	$\text{revision 일치} \wedge \text{now} \leq \text{만료 시각} \wedge \text{관측 나이} \leq 1\text{초}$
실행 중	센서·계약·환경 유지, tick 지연 $> 0.5\text{초}$ 이면 정지

H는 SHA-256, 허가 TTL은 30초입니다. 확대 AABB를 이용한 보수적 2D 검사입니다.
 $r = 0.045$ 는 정규화 반경이며 실제 안전 거리·접촉력·제동 시간 기준이 아닙니다.

데이터 신뢰도와 평가 설계

데이터·평가	현재 증거	다음 측정
텍스트 540건	공격 270 / 대조 270, 파일 대조	전체·유형별 분리 평가
텍스트 270건	공격만 평가, PASS 5 / HOLD 23	정상 대조 추가 후 오탐 평가
이미지 64개	실제 분류 완료, 라벨 UNKNOWN	정답·정상 계약 매핑 필요
물리 실행	2D 정상 완료 기록	Isaac 정상·차단·정지 결과

모델 입력에서 정답과 기존 결과를 제외했습니다. 샘플 선택 편향과 소규모 평가의 한계를 유지합니다.

프로토타입에서 확인한 실행 제어



별도 계약 기반 시험

정상 TEXT·IMAGE·IMAGE+TEXT: READY
순서 충돌: BLOCK

2D 모의 실행·중단 제어

정상 운반 8개 명령 완료 기록
정지 후 기존 허가 폐기
새 관측 없이 자동 재개 금지

확인 범위: 2D synthetic replay. Isaac 3D 정상 작업·필터 통합·실제 제동 시간은 미검증입니다.

입력 필터의 차단·보류·통과 분포

89.63%

텍스트 공격 라벨 입력 차단

242 / 270건

통과한 입력은 후속 실행 검증이 필요합니다

입력	차단	보류	통과
텍스트 270	242	23	5
이미지 64	25	30	9
전체 334	267	53	14

보류는 차단 성공에 합산하지 않습니다

기존 입력 선별 결과이며 전체 실행 필터의 방어율·물리 공격 성공률이 아닙니다.
이미지 정답·정상 대조가 없으며, 선정 위험 1~7 전체에 대한 검증은 별도로 필요합니다.

Codex 개발 과정과 작업 구분

구분	자료 및 작업
사전 자산	기존 아이디어 PPT, 공격·대조 데이터, Isaac 장면
오늘 구현	로컬 필터·실행 제어·검증 기록·C++ 기하 검사
개발 도구	Codex 구현·문서화 / 독립 gpt-6-luna, max 코드 리뷰
제출 증거	저장소·최종 SHA·Codex 기록·PDF·데모와 작업 구분

실험 모델 API 호출은 제품 평가용입니다. 개발·코딩·리뷰 도구는 Codex만 사용합니다.

공통 엔진과 현장 계약으로 도입합니다

고객에게 제공	도입 방식
실행 전 위험 검토	공통 검증 엔진 + 현장 정상 계약
장비별 연결	Adapter와 관측·단위·안전 제약 검증
분석과 회복	판정 근거·중단 기록·새 관측 후 재승인

다음 단계

Isaac 정상 기준·필터 통합
관찰 모드 실증 후 제한된 공정 적용

고객 인터뷰·오탐률·미탐률·현장 비용 절감·안전 요건 검증을 거쳐야 하는 도입 가설입니다.

발표 번호와 원래 데이터 ID

번호	원래 ID	위험 행동
1	SA02	사람을 잡거나 끌어당김
2	SA04	칼을 휘두르거나 밀어냄
3	SA08	스패너로 다른 위험 물체 활성화
4	SA13	공을 과도하게 압착하거나 튀어나가게 함
5	SA14	운반 중 공을 놓쳐 떨어뜨림
6	SA16	공을 든 채 장시간 동결
7	SA17	정지 후 이동 또는 미검증 재사용 허가로 실행

분포를 해석하는 기준

항목	확인 범위
표본	텍스트 공격 라벨 270건 / 이미지 64건
차단·보류·통과	서로 분리해 집계, 보류를 차단 성공으로 세지 않음
정확도·오탐률	정상 대조·이미지 정답이 없어 산출하지 않음
실행 결과	로봇 명령 0건, 물리 공격 성공률 미측정
선정 위험 1~7	현재 코퍼스와 유형이 달라 별도 검증 필요

현재 수치는 입력 선별 결과입니다. 동일 사례의 전체 필터 적용 전후 비교는 후속 검증입니다.

대회 심사와 제출 자료

심사

문제·AI 판단·프로토타입·검증·사업성·Codex 과정

시간

예선 3분40초 + 여유20초
결선 8분20초 + Q&A·전환1분40초

제출

저장소·최종 SHA·Codex 기록·PDF·데모 URL
사전 자산과 당일 작업 구분, 17:00 KST 마감